

数据说明

对应赛题《算力约束下提升大语言模型能力的资源配置建模》。本说明给出各数据文件的结构、字段与跨附件兼容性；各文件均使用英文文件名，赛题正文中以编号 A1–A18、B1–B12、C1–C10 指代，编号与英文文件名的对照见《编号与读取速查》。

本赛题以真实公开数据为主，并包含经真实数据校准、已明确标注的半合成补充数据。全部附件位于 `real_attachments/` 目录下，本文所有路径均相对于该目录。按实际文件占用的存储空间（即磁盘上的字节数）统计，总体积约 0.55 GB（压缩后，原始约 1.66 GB），其中绝大部分为必用数据（见《强制使用清单》）。参赛队伍可在个人电脑上使用 Python、Matlab 或 R 完成全部处理，无须 GPU。

如本文档、`source_manifest.json`、`attachment_size_summary.csv` 与实际文件出现差异，以实际附件为准。

编号与读取速查

本节集中给出编号索引、各文件绑定问题与读取要求，便于与赛题正文分开查阅。各文件的完整字段与规模见后文《附件 A/B/C》各节。

数据总表

下表为各数据文件的编号—英文文件名对照，并标出每个文件绑定的问题与在解题中的角色。

性质栏口径统一如下：**真实** = 直接观测或公开数据；**半合成** = 基于真实数据校准并叠加噪声；**外推/估算** = 由模型外推或预估，非直接观测；**插值** = 由检查点插值生成；**子集** = 取自其他表的子集，非独立实验；**混合** = 来源口径不完全统一，须分层使用；**参考/说明** = 辅助文件。

附件 A（问题一）A_data_value/

编号	英文文件名	中文说明	性质	绑定问题 · 角色
A1	A_data_value/slimpajama_quality_signal_sample.jsonl.xz	质量信号抽样集 (51,230 条, 27 字段; 来自 SlimPajama-Meta-rater 按域抽样)	真实	问题一 · 质量主样本
A2	A_data_value/slimpajama_quality_extended/arxiv_*.jsonl.xz	arxiv 扩展质量信号	真实	问题一 · 必用

编号	英文文件名	中文说明	性质	绑定问题 · 角色
A3	A_data_value/slimpajama_quality_extended/github_b_*.jsonl.xz	github 扩展质量信号	真实	问题一 · 必用
A4	A_data_value/regmix_tables/train_mixture_1m.csv	训练配比 (512 组)	真实	问题一 · 配方 · 训练
A5	A_data_value/regmix_tables/train_pile_loss_1m.csv	训练 Loss	真实	问题一 · Loss · 训练
A6	A_data_value/regmix_tables/test_mixture_1m.csv	检验配比 1M (256 组)	真实	问题一 · 配方 · 检验
A7	A_data_value/regmix_tables/test_pile_loss_1m.csv	检验 Loss 1M	真实	问题一 · Loss · 检验
A8	A_data_value/regmix_tables/test_mixture_60m.csv	检验配比 60M	真实	问题一 · 配方 · 检验
A9	A_data_value/regmix_tables/test_pile_loss_60m.csv	检验 Loss 60M	真实	问题一 · Loss · 检验
A10	A_data_value/regmix_tables/test_mixture_1B.csv	检验配比 1B (64 组)	真实	问题一 · 配方 · 检验
A11	A_data_value/regmix_tables/test_pile_loss_1B.csv	检验 Loss 1B	真实	问题一 · Loss · 检验
A12	A_data_value/regmix_tables/est_mixture_10b.csv	外推配比 10B (train 子集)	子集	问题一 · 配方 · 外推
A13	A_data_value/regmix_tables/est_pile_loss_10b.csv	外推 Loss 10B	外推	问题一 · Loss · 外推
A14	A_data_value/regmix_tables/est_mixture_70b.csv	外推配比 70B (train 子集)	子集	问题一 · 配方 · 外推
A15	A_data_value/regmix_tables/est_pile_loss_70b.csv	外推 Loss 70B	外推	问题一 · Loss · 外推
A16	A_data_value/domain_mapping_guide.csv	17 域 → 质量域映射表	参考	问题一 · 域映射

编号	英文文件名	中文说明	性质	绑定问题·角色
A17	A_data_value/regmix_domain_summary.csv	域摘要	真实	问题一·辅助（本版未接入求解，供扩展分析）
A18	A_data_value/regmix_domain_sample.jsonl.xz	域原始文本样例	真实	可选·辅助

说明：A4–A5 为训练表 (train)，A6–A11 为检验表 (test)，A12–A15 为外推表 (est, 即 estimated)。配方表与对应 Loss 表各为一个文件，按 index 列对应。

附件 B（问题二）B_scaling_laws/

编号	英文文件名	中文说明	性质	绑定问题·角色
B1	B_scaling_laws/pythia_training_log_existing.csv	Pythia 训练日志 (1,176 行)	真实	问题二·主拟合
B2	B_scaling_laws/cerebras_training_log.csv	Cerebras 训练日志 (1,029 行)	半合成	问题二·族外验证
B3	B_scaling_laws/training_trajectories/ (8 个)	Pythia 插值轨迹 (8×500)	插值	问题二·轨迹验证
B4	B_scaling_laws/scaling_baseline.csv	跨族收敛点 (57 行, 12 族)	真实	问题二·跨族验证
B5	B_scaling_laws/published_scaling_data.csv	文献标度律数据 (44 行)	真实	问题二·文献验证
B6	B_scaling_laws/supplementary_NQ_experiment.csv	NQ 半合成实验 (360 点)	半合成	问题二·质量 Q·基础
B7	B_scaling_laws/supplementary_NQ_experiment_expanded.csv	NQ 半合成实验 (450 点)	半合成	问题二·质量 Q·扩展
B8	B_scaling_laws/supplementary_NQ_experiment_large.csv	NQ 半合成实验 (1,704 点, 含外推)	半合成	问题二·质量 Q·大规模
B9	B_scaling_laws/supplementary_large_models.csv	大模型元数据 (100B–10000B)	真实	问题二·大模型参数
B10	B_scaling_laws/supplementary_large_baseline.csv	大模型预估 Loss (100B–10000B)	估算	问题二·大模型外推
B11	B_scaling_laws/open_model_family_metadata.csv	模型族元数据	真实	问题二·辅助

编号	英文文件名	中文说明	性质	绑定问题 · 角色
B12	B_scaling_laws/pythia_c checkpoint_index.csv	Pythia 检查点索引	真实	问题二 · 辅助

说明：B1 为主拟合数据；B2/B3 用于模型族外或插值轨迹验证；B4/B5 用于跨族或文献验证；B6–B8 是唯一含质量 Q 的数据，用于把 Q 纳入标度律；B9/B10 用于百亿参数以上外推。

问题二在问题一输出的质量评分 Q 与配比 p 基础上构建广义标度律；附件 A 为同一数据集，本问不直接重复读取其原始文件，质量与配比信息通过问题一结果引入。

附件 C（问题三、四）C_efficiency_evolution/

编号	英文文件名	中文说明	性质	绑定问题 · 角色
C1	C_efficiency_evolution/ leaderboard_cleaned.csv	排行榜（4,576 行，6 维）	真实	问题四 · 主用
C2	C_efficiency_evolution/ leaderboard_enhanced.csv	排行榜增强	真实	问题四 · 可替代 C1
C3	C_efficiency_evolution/ leaderboard_extended_time_series.csv	排行榜时序	混合	问题四 · 时序
C4	C_efficiency_evolution/ epoch_all_ai_models.csv	全模型元数据	真实	问题四 · 宏观元数据
C5	C_efficiency_evolution/ loss_benchmark_bridge.csv	Loss–Benchmark 桥接（43 条）	混合	问题四 · 桥接 · 可对照
C6	C_efficiency_evolution/ loss_benchmark_bridge_expanded.csv	桥接扩展（75 条）	混合	问题四 · 桥接 · 主用
C7	C_efficiency_evolution/ model_architecture_metadata.csv	架构元数据（含上下文长度）	真实	问题三 · 主用；问题四
C8	C_efficiency_evolution/ detailed_results/（1,863 目录 / 1,958 JSON）	逐任务评测 JSON（约 0.23 GB）	真实	问题四 · 必用
C9	C_efficiency_evolution/ data/*.parquet	Leaderboard 原始 Parquet	真实	问题四 · 与 C1 等价（本版未使用，供扩展分析）
C10	C_efficiency_evolution/ pythia*_eval_details/	评测说明目录（仅 README）	说明	参考 · 不可替代 C8

说明：问题三除 C7 外，另需使用问题一、二的输出（质量评分、配比、标度律参数）。

数据读取说明

数据可能存在缺失、噪声与冗余，须由参赛队伍自行预处理。大文件已提供 xz 压缩版（.jsonl.xz），可用 Python 的 `lzma.open()` 直接读取，无须解压。

- **流式与分块**：流式即逐行读取，分块即按固定行数批量读取，目的都是避免将大文件一次性载入内存。附件 A 质量信号 JSONL（A1–A3）宜流式或分块读取；不得以内存为由放弃大文件。
- **大文本字段**：`content` / `text` 字段若仅用于统计特征，可不全文入库，仅在线提取统计量。
- **附件 A**：A4 与 A5 通过 `index` 列对应；配比列为 `train_the_pile_*`（17 列），Loss 列为 `metric/the_pile*_val_loss`（13 列）。
- **附件 B**：B1 每行记录某模型在某时刻的 `N_params_B`、`D_tokens_B` 与 `val_loss`。
- **附件 C**：C1 含 IFEval、BBH、MATH Lvl 5、GPQA、MUSR、MMLU-PRO 六维得分；C8 下每个子目录对应一个模型的逐任务 JSON。
- **单位换算（全文通用）**：`N_params_B`、`D_tokens_B` 以十亿为单位（如 1.04 表示 1.04×10^9 ），代入 $C = 6ND$ 时须乘以 10^9 ；`C_FLOPs_1e21` 的单位为 10^{21} FLOPs。

强制使用清单

优先级	路径	约计体积	绑定问题	最低使用方式
必用	A_data_value/slimpajam a_quality_extended/*.jsonl.xz	约 0.04 GB (压缩)	问题一	处理全文记录，估计 arxiv/github 域级 Q ，并与 抽样集对照
必用	A_data_value/slimpajam a_quality_signal_sample.jsonl.xz	~0.10 GB (压缩)	问题一	22 维质量评价与冲突消解 主样本
必用	C_efficiency_evolution /detailed_results/	~0.23 GB	问题四	至少一项逐任务聚合分析
必用	附件 A/B/C 全部主 CSV (配方、Pythia、榜单、桥 接、架构、Epoch 等)	数十 MB	各问	按赛题要求接入模型
任选其一	C_efficiency_evolution /data/*.parquet 与 leaderboard/*.csv	~1 MB	问题四	CSV 与 Parquet 内容等价， 不必重复计算

跨附件兼容性与表头速查

附件	核心文件	关键字段	兼容性与连接键
A	A_data_value/regmix_tables/train_mixture_1m.csv	index, 17 个域配比	通过 index 与 Loss 表对应
A	A_data_value/regmix_tables/train_pile_loss_1m.csv	index, 13 个域 Loss	通过 index 与配方表对应
A	A_data_value/slimpajama_quality_signal_sample.jsonl.xz	_source_domain, 22 个质量指标	需通过领域映射与 17 域体系建立联系
A	A_data_value/slimpajama_quality_extended/*.jsonl.xz	同质量指标字段	必用；与抽样集字段一致，覆盖 arxiv/github
A	A_data_value/regmix_domain_sample.jsonl.xz	text, _source_domain	可选；辅助跨域映射
A	A_data_value/domain_mapping_guide.csv	mixture_domain, quality_domain, mapping_type	17 个配方域到质量域的参考映射
B	B_scaling_laws/pythia_training_log_existin g.csv	N_params_B, D_tokens_B, val_loss	真实训练轨迹；标度律拟合核心数据
B	B_scaling_laws/scaling_baseline.csv	family, N_params_B, D_tokens_B, val_loss	跨族收敛点；泛化验证
B	B_scaling_laws/supplementary_NQ_experiment.csv	N_params_B, D_tokens_B, Q_score, val_loss	半合成 N-D-Q 实验点
C	C_efficiency_evolution/leaderboard_cleaned.csv	Model, #Params (B), Submission Date, 6 维得分	核心评测表
C	C_efficiency_evolution/loss_benchmark_bridge_expanded.csv	Model, Val_Loss, LB_*, Loss_Comparability	Loss 到 Benchmark 桥接；按可比性分层
C	C_efficiency_evolution/model_architecture_metadata.csv	model_name, n_layers, n_heads, max_position_embeddings	架构和上下文长度分析
C	C_efficiency_evolution/detailed_results/	逐任务 JSON	必用；细粒度评测聚合

附件 A：数据配方实验与质量信号

数据来源

- 配方实验数据：RegMix 项目 (ICML 2024), <https://github.com/sail-sg/regmix>
- 质量信号数据与扩展质量信号 (arxiv、github 两域完整数据文件)：SlimPajama-Meta-rater, <https://huggingface.co/datasets/opendatalab/SlimPajama-Meta-rater>; 其中 A1 抽样集为该数据源各质量信号域的按域抽样记录，非另行生成的独立实验数据

文件结构与说明

文件	格式	规模	性质	说明
A_data_value/regmix_tables/train_mixture_1m.csv	CSV	512 行 × 18 列	真实	512 个训练配方，17 个 The Pile 子领域配比
A_data_value/regmix_tables/train_pile_loss_1m.csv	CSV	512 行 × 14 列	真实	对应配方的 13 个验证域交叉熵损失
A_data_value/regmix_tables/test_mixture_1m.csv	CSV	256 行 × 18 列	真实	1M 参数规模检验配方
A_data_value/regmix_tables/test_pile_loss_1m.csv	CSV	256 行 × 14 列	真实	1M 检验配方对应 Loss
A_data_value/regmix_tables/test_mixture_60m.csv	CSV	256 行 × 18 列	真实	60M 参数规模检验配方
A_data_value/regmix_tables/test_pile_loss_60m.csv	CSV	256 行 × 14 列	真实	60M 检验配方对应 Loss
A_data_value/regmix_tables/test_mixture_1B.csv	CSV	64 行 × 18 列	真实	1B 参数规模检验配方
A_data_value/regmix_tables/test_pile_loss_1B.csv	CSV	64 行 × 14 列	真实	1B 检验配方对应 Loss

文件	格式	规模	性质	说明
A_data_value/regmix_tables/est_pile_loss_10b.csv	CSV	63 行 × 14 列	外推	10B 尺度预估配方 Loss
A_data_value/regmix_tables/est_pile_loss_70b.csv	CSV	63 行 × 14 列	外推	70B 尺度预估配方 Loss
A_data_value/regmix_tables/est_mixture_10b.csv	CSV	63 行 × 18 列	子集	10B 尺度配比 (train 子集)
A_data_value/regmix_tables/est_mixture_70b.csv	CSV	63 行 × 18 列	子集	70B 尺度配比 (train 子集)
A_data_value/regmix_domain_summary.csv	CSV	17 行 × 5 列	真实	各领域文本抽样统计信息
A_data_value/domain_mapping_guide.csv	CSV	17 行 × 4 列	参考	17 个配方域与质量信号域的映射指南
A_data_value/slimpajama_quality_signal_sample.jsonl.xz	JSONL (xz 压缩)	51,230 条 × 27 字段	真实	22 个质量指标, 覆盖 7 个域; SlimPajama-Meta-rater 质量信号按域抽样子集 (必用)
A_data_value/slimpajama_quality_extended/arxiv_*.jsonl.xz	JSONL (xz 压缩)	17,523 条 × 24 字段	真实	arxiv 域扩展质量信号 (必用, 约 3.5 MB (压缩))
A_data_value/slimpajama_quality_extended/github_*.jsonl.xz	JSONL (xz 压缩)	203,752 条 × 24 字段	真实	github 域扩展质量信号 (必用, 约 36 MB (压缩))
A_data_value/regmix_domain_sample.jsonl.xz	JSONL (xz 压缩)	138,034 条	真实	RegMix 各域原始文本抽样 (可选, 约 0.16 GB (xz 压缩))

性质说明: **真实** = 来自公开论文与数据集的直接观测值。**外推** = est_pile_loss_10b.csv、est_pile_loss_70b.csv 从 1M/60M/1B 三尺度幂律外推, 非直接观测。**子集** = est_mixture_10b.csv、est_mixture_70b.csv 取自 train 配比子集, 非独立实验。**参考** = domain_mapping_guide.csv 为人工整理, 非实验数据。

核心字段说明

配方表: `index` 为配方编号; `train_the_pile_*` 共 17 列, 表示 17 个 The Pile 子领域的训练配比 (即领域配比 p 的取值), 每行和约为 1 (存在千分位级舍入误差)。

17 个训练领域: `arxiv`, `freelaw`, `nih_exporter`, `pubmed_central`, `wikipedia_en`, `dm_mathematics`, `github`, `philpapers`, `stackexchange`, `enron_emails`, `gutenberg_pg_19`, `pile_cc`, `ubuntu_irc`, `europarl`, `hackernews`, `pubmed_abstracts`, `uspto_backgrounds`。

Loss 表: `index` 对应配方编号; `metric/the_pile_*_val_loss` 共 13 列。17 个训练域中, `nih_exporter`、`enron_emails`、`europarl`、`philpapers` 仅有训练配比列, 无对应交叉熵损失列。参赛队伍可选择保留、合并、正则化处理或仅在训练配比模型中解释其间接影响, 但需说明理由。

质量信号: **A1** 每行一个 JSON 对象, 共 27 个字段, 其中 22 个为质量指标字段 (14 个标量指标 + 8 个多维列表型指标), 其余 5 个为辅助字段 (`id`、`content`、`sub_path`、`_source_domain`、`_source_path`)。**A2/A3** 每行 24 个字段, 为 22 个质量指标、`id` 与 `sub_path`; 已去除 `content`、`_source_domain`、`_source_path`, 来源域由文件名或路径推断。

22 个质量指标: `fineweb_edu`, `fluency_en`, `modernbert_cleanliness`, `modernbert_readability`, `modernbert_reasoning`, `modernbert_professionalism`, `dsir_books`, `dsir_wiki`, `dsir_math`, `qurater`, `ad_en`, `rps_doc_word_count`, `rps_doc_num_sentences`, `rps_doc_unigram_entropy`, `rps_doc_frac_unique_words`, `rps_doc_frac_no_alph_words`, `rps_doc_frac_chars_top_2gram`, `rps_doc_frac_chars_top_3gram`, `rps_lines_uppercase_letter_fraction`, `rps_lines_ending_with_terminal_punctuation`, `rps_lines_numerical_chars_fraction`, `rps_doc_mean_word_length`。

其中 8 个列表型字段需先压缩为标量后再参与建模。扩展集与抽样集的 22 个质量指标字段一致, 宜使用同一套预处理流程。

域映射: 质量信号覆盖 7 个域 (`arxiv`、`book`、`c4`、`commoncrawl`、`github`、`stackexchange`、`wikipedia`), 配方实验涉及上述 17 个域。二者域名并不一一相同。`domain_mapping_guide.csv` 以配方域为行, 给出到质量域的参考对应: `direct` / `near_direct` / `inferred`。其中 `c4` 仅出现在质量信号侧, 配方 17 域中无同名列。

附件 B: 模型训练动态轨迹与标度律补充数据

数据来源

- Pythia 训练日志: EleutherAI Pythia Scaling Suite, <https://github.com/EleutherAI/pythia>
- Cerebras-GPT 轨迹: 根据 Pythia 标度律和公开 Cerebras-GPT 训练设定校准生成
- 跨族基准点: 从公开模型族文档与论文整理
- 大模型缩放参数: Epoch AI 数据库, https://epoch.ai/data/all_ai_models.csv
- 已发表标度律数据: Kaplan et al. (2020)、Hoffmann et al. (2022) 等文献

文件结构与说明

文件	格式	规模	性质	说明
B_scaling_laws/pythia_training_log_existing.csv	CSV	1,176 行 × 15 列	真实	8 个 Pythia 模型检查点的真实训练轨迹
B_scaling_laws/cerebras_training_log.csv	CSV	1,029 行 × 15 列	半合成	7 个 Cerebras 模型训练轨迹（校准 + 噪声）
B_scaling_laws/scaling_baseline.csv	CSV	57 行 × 5 列	真实	12 个模型族的跨族收敛基准点
B_scaling_laws/supplementary_NQ_experiment.csv	CSV	360 行	半合成	N-D-Q 实验点
B_scaling_laws/supplementary_NQ_experiment_expanded.csv	CSV	450 行	半合成	扩展版
B_scaling_laws/supplementary_NQ_experiment_large.csv	CSV	1,704 行	半合成	大规模矩阵，含更大参数外推
B_scaling_laws/supplementary_large_models.csv	CSV	132 行	真实	100B 以上开源模型缩放参数（Epoch AI 公开报告值）
B_scaling_laws/supplementary_large_baseline.csv	CSV	128 行	估算	100B 以上模型预估 Loss
B_scaling_laws/published_scaling_data.csv	CSV	44 行	真实	已发表标度律基准点
B_scaling_laws/training_trajectories/*.csv	CSV	8 × 500 = 4,000 行	插值	8 个 Pythia 模型插值训练轨迹
B_scaling_laws/pythia_checkpoint_index.csv	CSV	1,386 行	真实	Pythia 检查点索引元数据
B_scaling_laws/open_model_family_metadata.csv	CSV	18 行	真实	模型族仓库元数据

性质说明：**真实** = 直接观测值或公开报告值。**半合成** = cerebras_training_log.csv、supplementary_NQ_experiment*.csv 基于真实标度律校准并叠加噪声，非直接实验观测。**估算** = supplementary_large_baseline.csv 用已拟合标度律参数估算 Loss，非观测值。**插值** = training_trajectories/*.csv 从 Pythia 检查点插值生成。

核心字段说明

pythia_training_log_existing.csv: N_params_B 为参数量, D_tokens_B 为已训练数据量, C_FLOPs_1e21 为累计计算量, val_loss 为验证集交叉熵损失。四者的单位换算统一见《数据读取说明》。

Pythia 日志中 C_FLOPs_1e21 与 6ND 的中位比值约为 1。Cerebras 半合成轨迹已统一 D_tokens_B 单位为十亿 tokens, 并与 C_FLOPs_1e21 保持 6ND 量级一致。

pythia_checkpoint_index.csv 收录多个 Pythia 模型的检查点索引, 而 pythia_training_log_existing.csv 仅包含其中 8 个模型 (约 70M–12B) 的训练轨迹。

标度律数据汇总

数据集	N 范围	来源
Pythia 真实轨迹 (1,176 点)	0.07–12B	EleutherAI Pythia
Cerebras 半合成轨迹 (1,029 点)	0.11–13B	Pythia 标度律校准
跨族收敛基准 (57 点)	0.07–72B	12 个模型族公开数据
已发表基准 (44 点)	约 0.5–280B	公开论文整理
大模型缩放参数 (132 点)	100B 以上	Epoch AI 数据库
N-D-Q 半合成实验 (360 / 450 / 1,704 点)	含更大参数外推	校准 + 插值 + 外推

附件 C：模型评测与演进数据

数据来源

- Open LLM Leaderboard v2: <https://huggingface.co/datasets/open-llm-leaderboard-old/results>
- Epoch AI Models Dataset: https://epoch.ai/data/all_ai_models.csv
- 技术报告与模型配置: 用于 Loss-Benchmark 桥接和架构元数据整理
- HuggingFace Open LLM Leaderboard 详细评测结果: <https://huggingface.co/datasets/open-llm-leaderboard/results>

文件结构与说明

文件	格式	规模	性质	说明
C_efficiency_evolution /leaderboard_cleaned.csv	CSV	4,576 行 × 12 列	真实	6 维 Benchmark 评测得分
C_efficiency_evolution /leaderboard_enhanced.csv	CSV	4,576 行 × 15 列	真实	cleaned + Epoch AI 发布日期等
C_efficiency_evolution /leaderboard_extended_timeseries.csv	CSV	4,599 行 × 11 列	混合	约 2019–2025 年时序（含历史模型）
C_efficiency_evolution /epoch_all_ai_models.csv	CSV	3,523 行 × 57 列	真实	Epoch AI 全量模型元数据（不含评测得分）
C_efficiency_evolution /loss_benchmark_bridge.csv	CSV	43 行	混合	原始 Loss-Benchmark 桥接
C_efficiency_evolution /loss_benchmark_bridge_expanded.csv	CSV	75 行	混合	扩展桥接（高可比 + 中可比）
C_efficiency_evolution /model_architecture_metadata.csv	CSV	45 行 × 7 列	真实	主流开源模型架构元数据
C_efficiency_evolution /detailed_results/	JSON	1,863 个模型子目录 / 1,958 个 JSON	真实	各模型 6 维 Benchmark 逐任务详细评测结果（必需，约 0.23 GB；4 个 JSON 截断，宜按目录取最新可解析记录）
C_efficiency_evolution /pythia*_eval_details/	文本	7 个目录	说明	目前仅含 README（数据集说明），不能替代 detailed_results/ 的逐任务 JSON
C_efficiency_evolution /data/train-00000-of-00001.parquet	Parquet	4,576 行 × 36 列	真实	原始 Leaderboard Parquet；核心六维与 C1 等价，另含原始附加列，任选其一

性质说明：**真实** = 来自公开 Leaderboard 或公开元数据（含 data/*.parquet）。**混合** = loss_benchmark_bridge*.csv 的 Loss 来源与验证集不完全统一，须按可比性分层；leaderboard_extended_timeseries.csv 不同年份评测标准可能不完全一致。**说明** = pythia*_eval_details

/ 仅含数据集说明文本。

核心字段说明

`leaderboard_cleaned.csv`: 关键字段包括 `Model`、`#Params (B)`、`Submission Date`、`IFEval / BBH / MATH Lvl 5 / GPQA / MUSR / MMLU-PRO` (6 维评测得分)、`均分列`、`Hub License`、`Type`。

`leaderboard_enhanced.csv`: 在 `cleaned` 基础上增加 Epoch AI 相关匹配列。

`epoch_all_ai_models.csv`: 不包含评测得分，主要提供发布时间、组织、参数量、训练计算量、训练数据量、开源权重等宏观元数据。部分文本字段可能包含换行，建议用标准 CSV 解析后计数。

Loss-Benchmark 桥接: `loss_benchmark_bridge_expanded.csv` 包含 75 个模型同时具备交叉熵损失与 6 维 Benchmark 得分。其中高可比样本主要来自 Pythia (Loss 可与附件 B 对照)，其余为中可比样本 (Loss 来源于不同技术报告或论文)。`Loss_Comparability` 字段标注可比性等级。

模型架构元数据: `model_architecture_metadata.csv` 包含层数、注意力头数、隐藏维度、词表大小、最大上下文长度 (`max_position_embeddings`) 和训练数据量等字段。模型名称与 Leaderboard 的 `Model` 字段不一定完全一致，匹配时需说明规则。

数据使用说明

1. 先满足问题绑定必用集，再展开方法设计；附录须附数据利用清单。
2. 半合成与外推数据 (`supplementary_NQ_experiment*.csv`、`cerebras_training_log.csv`、`est_pile_loss*.csv`、`supplementary_large_baseline.csv`) 非直接观测，应在论文中标注。
3. `scaling_baseline.csv` 可用于跨族验证；若用作盲测，应说明其与训练日志的近邻关系。
4. 开源筛选可依据 Leaderboard 的 `Hub License` 或 Epoch AI 的 `Open model weights?`，须说明口径。
5. 三套附件数据源相互独立采集，四问建模逻辑需递进耦合；桥接关系主要通过 `Loss`、`Model`、`(N, D)` 与领域映射建立。
6. C8 共 1,863 个模型子目录、1,958 个 JSON；其中 4 个 JSON 截断，1,860 个目录含至少一个可解析 JSON，1,854 个模型六维完整。逐任务聚合时宜按目录取最新可解析记录，跳过损坏文件并说明处理方式。